



UNIVERSIDAD NACIONAL AUTÓNOMA DE MÉXICO  
MAESTRÍA EN CIENCIAS MATEMÁTICAS

---

# Interpretabilidad de los Ataques Adversarios

---

REPORTE DEL PROYECTO FINAL  
- REDES NEURONALES -

Aaron Kelley

Rodrigo Fritz

18 de junio, 2021

# Abstract

Abstract Goes here

Keywords:

## Índice

<b>1. Introducción</b>	<b>2</b>
<b>2. Método</b>	<b>3</b>
2.1. Datos . . . . .	3
2.1.1. MNIST . . . . .	3
2.1.2. CIFAR-10 . . . . .	4
2.2. Ataques . . . . .	6
2.2.1. Fast Gradient Method . . . . .	6
2.2.2. Carlini & Wagner . . . . .	6
2.3. Defensas . . . . .	8
2.3.1. Compresión JPEG . . . . .	8
<b>3. Resultados</b>	<b>9</b>
3.1. Función Transferencia de las Redes . . . . .	9
3.2. ¿Qué hace la defensa de JPEG? . . . . .	10
3.3. Los efectos de Overfitting y Overparameterization . . . . .	11
3.4. Saliency . . . . .	13

## Development Notes/Ideas

- maybe we should take out Projected Gradient Descent
- with cleverhans we can do targeted attacks with Fast Gradient Descent

# 1. Introducción

Las redes neuronales profundas (DNNs) han ganado una alta reputación con respecto a sus capacidades de clasificar imágenes igual (o hasta superior) que los humanos. Pero en el pasado reciente, ha quedado cada vez más claro que las redes aprenden a clasificar de manera muy distinta que los humanos. Una de las propiedades que realmente demostró eso fue el descubrimiento de su susceptibilidad a los ataques adversarios [13]. Esos ataques se construyen agregándoles a las imágenes una pequeña perturbación imperceptible para los humanos que engaña a la red. Es decir, aunque una imagen adversaria para nosotros parezca igual a la original, la red se equivoca con la clasificación de la adversaria con alta probabilidad. Como los ataques pueden no ser detectables por los humanos, se plantea la preocupación que puedan ser usados maliciosamente; por ejemplo, en la tecnología de reconocimiento de imágenes que se utiliza en los automóviles autónomos. Por eso se requiere más profundización del conocimiento asociado.

A grandes rasgos, los ataques pueden dividirse entre dos categorías: dirigidos y no-dirigidos. Primero hablemos de los ataques dirigidos; muchos usan el gradiente de manera directa. La idea es que se toma el gradiente de la función de pérdida con respecto a la imagen, y eso se usa para diseñar una perturbación que maximiza el error de la clasificación cuando se le agrega a la imagen. Dos ejemplos de ataques no-dirigidos que utilizan el gradiente directamente son el projected gradient descent (PGD) [9] y el fast gradient sign method (FGSM) [3]. Este último saca el signo de cada elemento del gradiente en lugar de usar el gradiente verdadero; eso hace que sea más rápido con grandes cantidades de datos. En este artículo se usan tanto PGD como FGSM para explorar los ataques no-dirigidos. El objetivo de los ataques no dirigidos es que cambien la clasificación correcta a cualquier otro ataque, mientras que los ataques dirigidos tienen una clasificación deseada a la que cambian la clasificación correcta. Se examina el ataque Carlini & Wager (CW), el cual puede actuar como dirigido o no-dirigido.

Cabe mencionar la diferencia entre los ataques de caja blanca y caja negra. En el primero, todos los detalles de la red (pesos, arquitectura, etc) son conocidos por el atacante. Por el contrario, en los ataques de caja blanca, los detalles son escondidos, y solo se conocen las entradas (inputs) y las salidas (outputs). Aunque parezca muy difícil, los ataques de caja negra son bastante exitosos por la facilidad de aproximar el gradiente solo por las entradas y las salidas. Los ataques que se emplean en este artículo son los de caja blanca.

Desde el descubrimiento de esa vulnerabilidad que tienen las DNN, se han diseñado defensas para tratar de combatir los ataques. Aunque ninguna defensa funciona para resistir completamente los ataques, muchas sí tienen efecto, y vale la pena explorar qué propiedades contribuyen a su éxito. Al igual que los ataques, las defensas también se pueden categorizar en dos modalidades. Las del primer tipo modifican el entrenamiento de la red para que la función de pérdida se vuelva más suave. Entre más suave esa función, más difícil será para que las perturbaciones pequeñas hagan cambios grandes. Un ejemplo conocido de este tipo es el entrenamiento adversario [3, 11, 13]. Las defensas del segundo tipo, y la que se estudia en este artículo, no modifican el entrenamiento ni la arquitectura, sino que utilizan un preprocesamiento en las imágenes de entrada. La defensa que se utiliza en este artículo es compresión JPEG [2].

## 2. Método

### 2.1. Datos

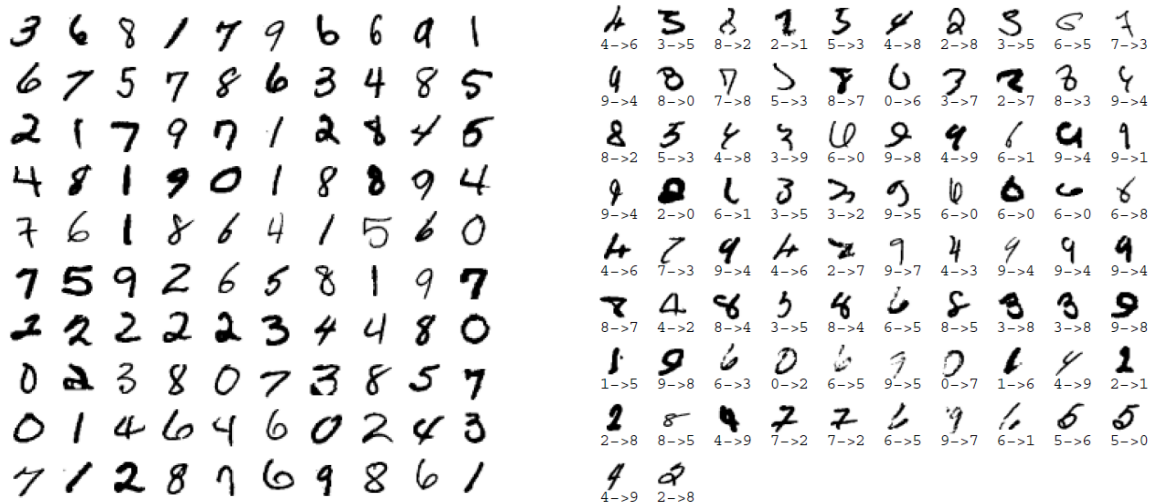
Para entrenar nuestras redes y probar los ataques adversarios y las defensas contra ellos, se emplearon las dos bases de datos más sencillas para procesamiento de imágenes: MNIST y CIFAR-10.

#### 2.1.1. MNIST

La base de datos MNIST es un compendio de los dígitos del 0 al 9 en letra manuscrita con 60,000 imágenes para entrenar a distintos sistemas de procesamiento de imágenes y 10,000 imágenes para evaluarlos. Se trata de un subconjunto de imágenes de un conjunto más grande que compiló el National Institute of Standards and Technology (NIST) del Departamento de Comercio los EEUU. Las siglas MNIST database significan Modified NIST database. Es una buena base de datos para probar técnicas de aprendizaje y métodos de reconocimiento de patrones con datos del mundo real empleando un esfuerzo mínimo en preprocesamiento y formato.

De las 10,000 imágenes de evaluación, la mitad fueron escritas por estudiantes de preparatoria y la otra mitad por empleados de la oficina de censos, mientras que de las 60,000 imágenes de entrenamiento, 58,527 de los números fueron escritos por 500 estudiantes y el resto por los empleados.

El tamaño de estas imágenes en blanco y negro fue normalizado a una caja de  $20 \times 20$  píxeles y se colocó su centro de masa en un campo de  $28 \times 28$  [6]. En la Figura 1 se muestran algunos ejemplos de estas imágenes.




(a) Algunas imágenes del conjunto de evaluación de la base de datos MNIST [7]


(b) 82 imágenes de evaluación que LeNet-5 clasificó erróneamente [7]

Figura 1: Imágenes de MNIST

La distribución de los dígitos en MNIST no es homogénea, como puede observarse en la Figura 4.




(a) Primeras 50 imágenes del conjunto **train** de MNIST con sus respectivas etiquetas




(b) 50 imágenes aleatorias del conjunto **train** de MNIST con sus respectivas etiquetas

Figura 2: Imágenes del conjunto de entrenamiento (train) de MNIST




(a) Primeras 50 imágenes del conjunto **test** de MNIST con sus respectivas etiquetas




(b) 50 imágenes aleatorias del conjunto **test** de MNIST con sus respectivas etiquetas

Figura 3: Imágenes del conjunto de evaluación (test) de MNIST



(a) Distribución de los dígitos en el conjunto de entrenamiento de MNIST



(b) Distribución de los dígitos en el conjunto de evaluación de MNIST

Figura 4: Distribución de los dígitos en MNIST

## 2.1.2. CIFAR-10

Los grupos del MIT y la NYU recopilaron un conjunto de millones de diminutas imágenes en color de la web, se trata de un excelente conjunto de datos para el entrenamiento no supervisado de modelos generativos profundos. Se crearon dos juegos de etiquetas confiables: el conjunto CIFAR-10, que tiene 6000 ejemplos de cada una de 10 clases y el conjunto CIFAR-100, que tiene 600 ejemplos de cada una de 100 clases que no se

superponen. Usando estas etiquetas, se mostró que el reconocimiento de objetos mejora significativamente al entrenar previamente una capa de características en un gran conjunto de imágenes diminutas sin etiquetar.

Esta base de datos fue ensamblada buscando en la web imágenes de cada sustantivo en inglés no abstracto en la base de datos léxica WordNet. Utilizaron varios motores de búsqueda, incluidos Google, Flickr y Altavista y mantuvieron aproximadamente los primeros 3000 resultados para cada término de búsqueda. Después de recopilar todas las imágenes para un término de búsqueda en particular, eliminaron duplicados perfectos e imágenes en las que una parte excesivamente grande de los píxeles eran blancos, ya que tendían a ser figuras sintéticas en lugar de imágenes naturales. El término de búsqueda utilizado para encontrar una imagen le proporciona una etiqueta aproximada, aunque es extremadamente poco confiable debido a la naturaleza de la tecnología de búsqueda de imágenes en línea. En total, el conjunto de datos contiene 80 millones de imágenes en color reducidas a  $32 \times 32$  y distribuidas en 79,000 términos de búsqueda [4].

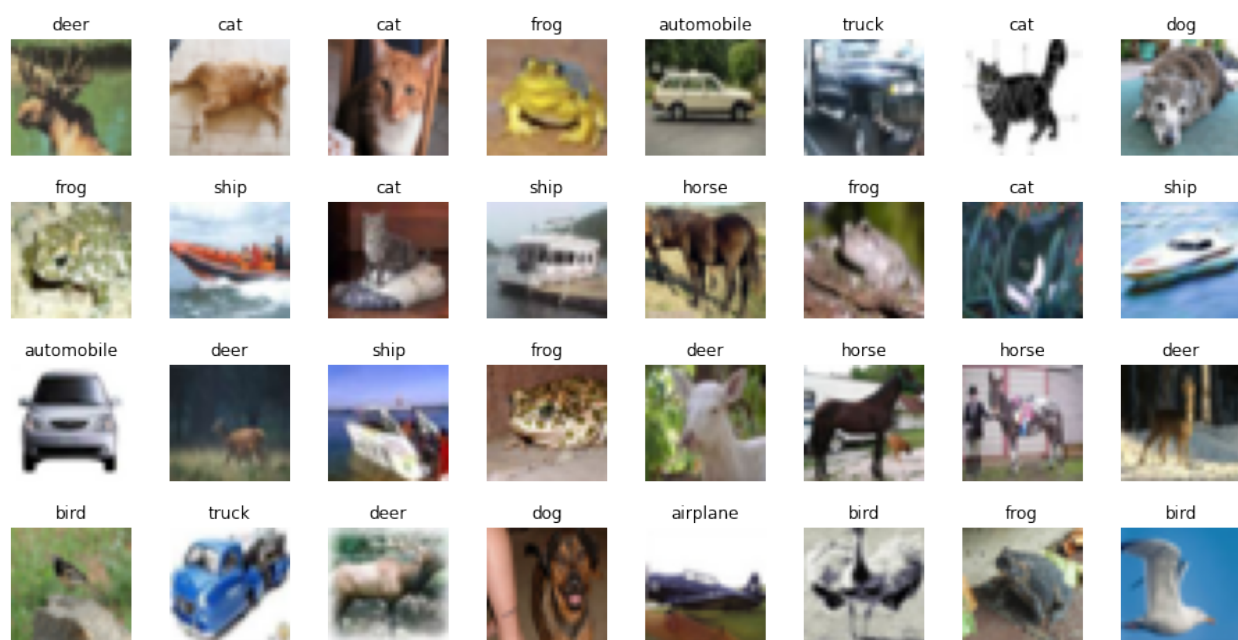


Figura 5: Algunas imágenes de la base de datos CIFAR-10

El conjunto de datos se divide en cinco lotes de entrenamiento y un lote de prueba, cada uno con 10,000 imágenes. El lote de prueba contiene exactamente 1000 imágenes seleccionadas al azar de cada clase. Los lotes de entrenamiento contienen las imágenes restantes en orden aleatorio, pero algunos lotes de entrenamiento pueden contener más imágenes de una clase que de otra. Entre ellos, los lotes de entrenamiento contienen exactamente 5000 imágenes de cada clase [5].

Las 10 clases de CIFAR-10 se encuentran en orden alfabético y son:

- |               |         |         |          |           |
|---------------|---------|---------|----------|-----------|
| 1. airplane   | 3. bird | 5. deer | 7. frog  | 9. ship   |
| 2. automobile | 4. cat  | 6. dog  | 8. horse | 10. truck |

## 2.2. Ataques

### 2.2.1. Fast Gradient Method

[3], maybe more

Sean  $\theta$  los parámetros de un modelo,  $x$  la entrada,  $y$  las salidas asociadas, y  $J(\theta, x, y)$  la función de costo. La función de costo se linealiza alrededor del valor actual de  $\theta$ . Sea  $\epsilon \in \mathbb{R}^+$ . Definamos la imagen adversaria

$$\tilde{x} = x + \epsilon \eta_{\text{opt}}$$

Se puede definir  $\eta_{\text{opt}}$  por el problema de optimización

$$\eta_{\text{opt}} = \underset{\eta}{\operatorname{argmax}} \left\{ \operatorname{grad}^\top \eta : \|\eta\|_p < \epsilon \right\}$$

Donde  $p \in \mathbb{N} \cup \{\infty\}$  y  $\operatorname{grad} = \nabla_x J(\theta, x, y)$ . Experimentamos con dos valores de  $p$ :

a)  $p = 2$ ,

$$\eta_{\text{opt}} = \frac{\operatorname{grad}}{\|\operatorname{grad}\|}$$

b)  $p = \infty$ ,

$$\eta_{\text{opt}} = \operatorname{sign}(\nabla_x J(\theta, x, y))$$

### 2.2.2. Carlini & Wagner

Nicholas Carlini y David Wagner [1] propusieron en 2017 un método para encontrar ejemplos adversarios que tuvieran poca distorsión en la norma  $L^2$ . Dada  $x$ , se escoge una clase  $t$  y se busca la  $\omega$  que resuelva

$$\text{minimize} \quad \left\| \frac{1}{2} (\tanh(\omega) + 1) - x \right\|^2 + c \cdot f\left(\frac{1}{2} (\tanh(\omega) + 1)\right)$$

con  $f$  definida como

$$f(x') = \max(\max\{Z(x')_i : i \neq t\} - Z(x')_t, -\kappa)$$

Esta  $f$  está basada en una función objetivo en la que se controla la confianza con la que ocurre una clasificación errónea al ajustar el valor de  $\kappa$ . El parámetro  $\kappa$  sugiere a quien esté resolviendo el problema encontrar una instancia adversaria  $x'$  que sea clasificada con mucha confianza como la clase  $t$ . Ellos toman  $\kappa = 0$ .  $Z(x)$  es el logit para  $x$ , es decir la pre-activación de la capa de salida softmax.

En la Figura 6 se observa que el ataque es totalmente imperceptible para nosotros. Aunque este ataque puede ser dirigido, se usa de la forma no dirigida en este reporte.

		Target Classification ( $L_2$ )									
		0	1	2	3	4	5	6	7	8	9
Source Classification	0										
	1										
	2										
	3										
	4										
	5										
	6										
	7										
	8										
	9										

Figura 6: Ataque de Carlini & Wagner con la norma  $L^2$  sobre MNIST aplicando un ataque dirigido para cada par fuente/objetivo (source/target)



(a) fgsm example



(b) fgm example



(c) CW example

Figura 7: stuff



## 2.3. Defensas

### 2.3.1. Compresión JPEG

Las siglas JPEG vienen de "Joint Photographic Experts Group", que es el nombre del grupo que creó el estándar en 1992, el cual es una compresión con pérdida que utiliza la transformada discreta del coseno (DCT), una técnica propuesta por Nasir Ahmed en 1972, y que normalmente elimina muchos componentes de alta frecuencia, a los que la percepción humana es menos sensible [2, 12]. Consta de los siguientes pasos:

1. Conversión de la imagen de formato RGB a formato  $YC_bC_r$ , donde el canal Y representa luminancia y los canales  $C_b$  y  $C_r$  representan crominancia. Esto está hecho porque el sistema visual humano se basa más en el contenido espacial y la agudeza que en el color para la interpretación.
2. Submuestreo espacial de los canales de crominancia en el espacio  $YC_bC_r$ : el ojo humano es mucho más sensible a los cambios de luminancia, y reducir la muestra de la información de crominancia no afecta mucho la percepción del ser humano de la imagen.
3. Dividir la imagen en bloques de  $8 \times 8$  y aplicar DCT en 2D a cada bloque. Esto se hace para cada canal por separado. Este paso produce mayor compresión de los datos de la imagen.
4. Cuantificación de las amplitudes de frecuencia, lograda dividiendo cada término de frecuencia por una constante (diferente) y redondeándola al número entero más cercano. Como resultado, muchos componentes de alta frecuencia generalmente se establecen en cero y otros se reducen. La cantidad de compresión se rige por un parámetro de calidad especificado por el usuario, que define la reducción en la resolución. Aquí es donde el algoritmo JPEG logra la mayor parte de la compresión, a expensas de la calidad de la imagen. Este paso suprime más las frecuencias más altas, ya que estos coeficientes contribuyen menos a la percepción humana de la imagen.
5. Compresión sin pérdidas de los datos del bloque.

En la Figura 8 se muestran 2 ejemplos de compresión JPEG con imágenes de MNIST (Fig. 8a) y CIFAR-10 (Fig. 8b), para distintos niveles de compresión, la cual aumenta como el inverso de la calidad.



Figura 8: Distintos niveles de compresión (inverso de la calidad) JPEG

### 3. Resultados

#### 3.1. Función Transferencia de las Redes

Una manera útil de pensar de una red es con un punto de vista basado en teoría de control. De esta forma, construimos una función de transferencia calculando la respuesta de la red a ciertas frecuencias.

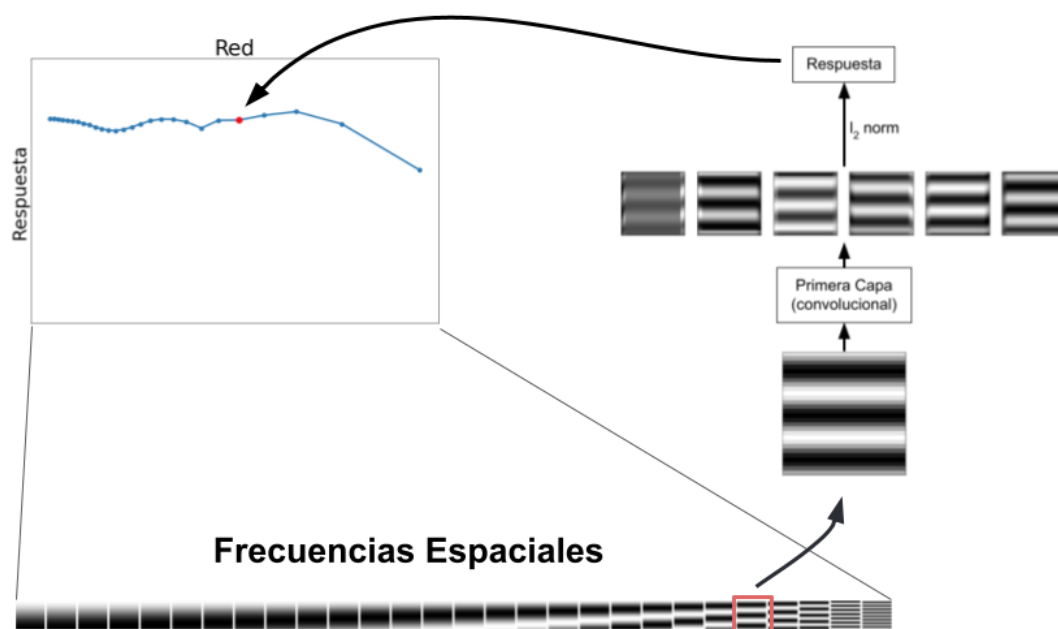



Figura 9: stuff

Así se puede ver las frecuencias a las que la red tiene mayor o menor sensibilidad.



### 3.2. ¿Qué hace la defensa de JPEG?

Como vimos en la sección de compresión JPEG, cuando esta es aplicada a una imagen que ha sido sometida a un ataque adversario, los componentes de alta frecuencia se eliminan y, así como los humanos percibimos en menor medida dichos componentes, es posible que la red no logre distinguir el ataque perpetrado sobre la imagen, esto debido a que los ataques suelen tratarse de pequeñas cantidades de ruido o distorsión introducidos en la imagen y, al reducir la calidad de la misma, la red tiene más probabilidades de recuperar la clasificación original de la imagen. Esto se encuentra esquematizado en la Figura 10.


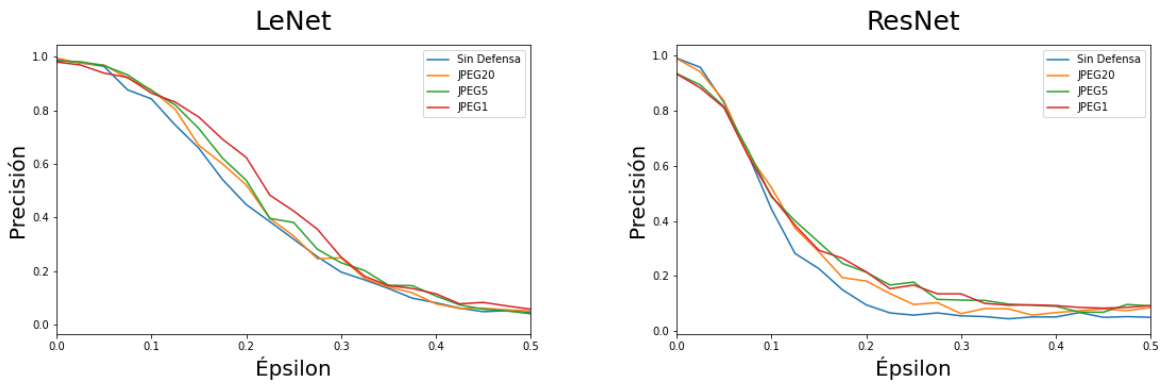


Figura 10: La defensa JPEG radica en contrarrestar el ruido agregado por el ataque adversario al remover los componentes de alta frecuencia, que son los causantes de la falla en la clasificación de la red. En este ejemplo, el dígito 5 es clasificado como un 3 con el ruido del ataque, pero al hacer una compresión JPEG, la red clasifica correctamente al dígito como un 5.

En la Figura 11 se muestra el resultado de nuestro entrenamiento de las redes LeNet y ResNet utilizando MNIST y el ataque FGSM con la norma  $L_\infty$  para distintos niveles de compresión JPEG como defensa. Se observa que, efectivamente, conforme aumenta la compresión (disminuye la calidad), la precisión (accuracy) en la clasificación de las imágenes por parte de la red es mayor. Nótese que con ResNet la precisión decae más rápidamente conforme aumenta el  $\epsilon$ .



(a) Compresión JPEG contra FGSM usando LeNet

(b) Compresión JPEG contra FGSM usando ResNet

Figura 11: Resultado de la compresión JPEG como defensa ante el ataque FGSM sobre MNIST

**to do:**

- Carlini Wagner attack graphs
- JPEG defense graphs with cifar10
- Bode diagrams with jpeg conversion as first layer

### 3.3. Los efectos de Overfitting y Overparameterization

Se ha sugerido que algunas propiedades de ciertas redes pueden contribuir a su susceptibilidad a los ataques adversarios. Por ejemplo, en el contexto de las imágenes médicas y sus redes respectivas, proponen que overfitting y overparameterization pueden actuar de esa manera [8]. *Overfitting* ocurre cuando el modelo clasifica bien los datos de entrenamiento, pero no se generaliza tan bien. Es decir, en los datos de validación, tiene peor desempeño. *Overparameterization* tiene lugar cuando hay tantos parámetros que la red es capaz de “memorizar” completamente los datos. Hacemos un pequeño análisis para probar esta hipótesis y no encontramos resultados que le apoyen. De hecho, con las redes que probamos, encontramos lo opuesto. En general, overfitting y overparameterization hacen que la red sea más robusta a los ataques adversarios (Figure 12).

Para explorar lo de overfitting, cinco redes fueron entrenadas usando distintos números de épocas (epochs). Entre más épocas, más probabilidad de que la red haya sido overfit. Para ver lo mismo con overparameterization,

seis redes fueron entrenadas con distintas cantidades de parámetros. Se le metieron un cierto número de capas (layers) adicionales directamente antes de la última. Cada capa adicional tenía 256 nodos. Así que, probamos redes con varios números de parámetros (Cuadro 1).

Red	Número de parámetros
Normal	61,706
2 Capas Adicionales	150,978
4 Capas Adicionales	282,562
6 Capas Adicionales	414,146
10 Capas Adicionales	743,106
20 Capas Adicionales	1,335,234

Cuadro 1: table

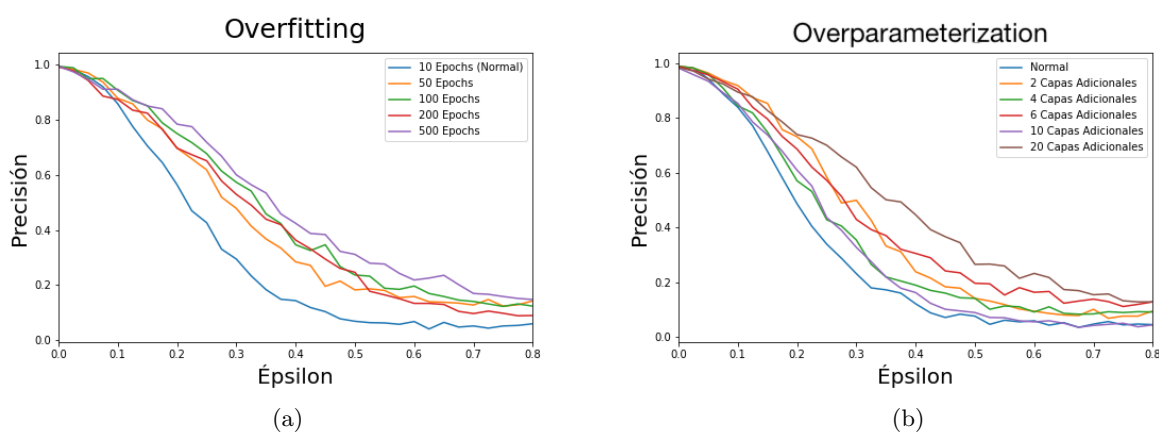


Figura 12: En (12a) se observa que conforme aumentamos el número de épocas (epochs), la precisión (accuracy) aumenta con respecto a cada  $\epsilon$ . Asimismo en (12b), en general, aumentar el número de capas (layers) aumenta la precisión

### 3.4. Saliency

- Show figures from notebook of how adversarial noise attacks parts of the image that seem vulnerable (for example changing a 3→8)
- Show Gradient-based localization of both image sets and how they change after adding adversarial noise[10]

## Referencias

- [1] Nicholas Carlini y David Wagner. *Towards Evaluating the Robustness of Neural Networks*. 2017. arXiv: 1608.04644 [cs.CR].
- [2] Nilaksh Das y col. *Keeping the Bad Guys Out: Protecting and Vaccinating Deep Learning with JPEG Compression*. 2017. arXiv: 1705.02900 [cs.CV].
- [3] Ian J. Goodfellow, Jonathon Shlens y Christian Szegedy. *Explaining and Harnessing Adversarial Examples*. 2015. arXiv: 1412.6572 [stat.ML].
- [4] Alex Krizhevsky. *Learning multiple layers of features from tiny images*. Inf. téc. 2009.
- [5] Alex Krizhevsky, Vinod Nair y Geoffrey Hinton. *The CIFAR-10 website*. 2009. URL: <http://www.cs.toronto.edu/~kriz/cifar.html>.
- [6] Yann LeCun, Corinna Cortes y CJ Burges. «MNIST handwritten digit database». En: *ATT Labs [Online]*. Available: <http://yann.lecun.com/exdb/mnist> 2 (2010).
- [7] Yann Lecun y col. «Gradient-based learning applied to document recognition». En: *Proceedings of the IEEE*. 1998, págs. 2278-2324.
- [8] Xingjun Ma y col. *Understanding Adversarial Attacks on Deep Learning Based Medical Image Analysis Systems*. 2020. arXiv: 1907.10456 [cs.CV].
- [9] Aleksander Madry y col. *Towards Deep Learning Models Resistant to Adversarial Attacks*. 2019. arXiv: 1706.06083 [stat.ML].
- [10] Ramprasaath R. Selvaraju y col. «Grad-CAM: Visual Explanations from Deep Networks via Gradient-Based Localization». En: *International Journal of Computer Vision* 128.2 (oct. de 2019), págs. 336-359. ISSN: 1573-1405. DOI: 10.1007/s11263-019-01228-7. URL: <http://dx.doi.org/10.1007/s11263-019-01228-7>.
- [11] Uri Shaham, Yutaro Yamada y Sahand Negahban. «Understanding adversarial training: Increasing local stability of supervised models through robust optimization». En: *Neurocomputing* 307 (sep. de 2018), págs. 195-204. ISSN: 0925-2312. DOI: 10.1016/j.neucom.2018.04.027. URL: <http://dx.doi.org/10.1016/j.neucom.2018.04.027>.
- [12] Uri Shaham y col. *Defending against Adversarial Images using Basis Functions Transformations*. 2018. arXiv: 1803.10840 [stat.ML].
- [13] Christian Szegedy y col. *Intriguing properties of neural networks*. 2014. arXiv: 1312.6199 [cs.CV].